



中国科学技术大学
University of Science and Technology of China

Follow The Regularized Leader

彭辉阳

USTC 管理学院

2025 年 5 月 27 日

- 1 在线镜像下降
- 2 Follow The Regularized Leader
- 3 Parameter-free 在线学习
- 4 参考文献





- 1 在线镜像下降
 - 从 OSD 出发与改进 ■ OMD 的性质
- 2 Follow The Regularized Leader
- 3 Parameter-free 在线学习
- 4 参考文献



- 1 在线镜像下降
 - 从 OSD 出发与改进 ■ OMD 的性质
- 2 Follow The Regularized Leader
- 3 Parameter-free 在线学习
- 4 参考文献

- ▶ 次梯度并不一定一直指向函数值在最小点。
- ▶ OSD 有效的依据是，次梯度指向其中一个函数值下降方向：

$$\ell(x_t) - \ell(u) \leq \langle g_t, x_t - u \rangle$$



由次梯度的定义, $f(x)$ 可由一个局部线性函数近似:

$$f(x) \geq \tilde{f}(x) = f(x_0) + \langle g, x - x_0 \rangle, \forall x \in V$$

然后我们将他限定在某一个小邻域内:

$$\begin{aligned} x_{t+1} = \arg \min_{x \in V} & f(x_t) + \langle g, x - x_t \rangle \\ \text{s.t. } & \|x_t - x\|^2 \leq h \end{aligned}$$

类似地, 对于某个 $\eta > 0$, 我们也能定义一个二次局部近似函数

$$\arg \min_{x \in V} \hat{f}(x) = f(x_0) + \langle g, x - x_0 \rangle + \frac{1}{2\eta} \|x_0 - x\|_2^2$$

最后一步，我们可以证明，对二次局部近似函数求最小值的过程，可以等效为我们在 OSD 中进行的迭代：

$$\begin{aligned}\arg \min_{x \in V} \langle g_t, x \rangle + \frac{1}{2\eta_t} \|x_t - x\|_2^2 &= \arg \min_{x \in V} \|\eta_t g_t\|^2 + 2\eta_t \langle g_t, x - x_t \rangle + \|x_t - x\|_2^2 \\ &= \arg \min_{x \in V} \|x_t - \eta_t g_t - x\|_2^2 \\ &= \Pi_V(x_t - \eta_t g_t)\end{aligned}$$

这里 $\Pi_V(x) = \arg \min_{y \in V} \|x - y\|_2$ 。

定义 (1)

设 $\psi : X \rightarrow \mathbb{R}$ 强凸、连续可微, 那么 **Bregman 散度**定义为: $B_\psi : X \times \text{int}(X) \rightarrow \mathbb{R}$

$$B_\psi(x; y) = \psi(x) - \psi(y) - \langle \nabla \psi(y), x - y \rangle.$$

我们将 Bregman 散度用作一种相似度的度量, 他有如下性质:

- ▶ $B_\psi(x; y) \geq 0$, 等号成立当且仅当 $x = y$ 。
- ▶ 大多数情况下 $B_\psi(x; y) \neq B_\psi(y; x)$, 无对称性。
- ▶ 三角不等式: $B_\psi(z; x) + B_\psi(x; y) - B_\psi(z; y) = \langle \nabla \psi(y) - \nabla \psi(x), z - x \rangle$ 。

由泰勒公式, 存在某个 $\alpha \in [0, 1]$, 且 $z = \alpha x + (1 - \alpha)y$:

$$B_\psi(x; y) = \psi(x) - \psi(y) - \langle \nabla \psi(y), x - y \rangle = \frac{1}{2}(x - y)^T \nabla^2 \psi(z)(x - y)$$

我们能看出这种度量依赖于 ψ 的 Hessian 矩阵信息。

另外, 如果 ψ 是 λ -强凸的, 那么有:

$$B_\psi(x; y) \geq \frac{\lambda}{2} \|x - y\|^2$$

Algorithm 1 在线镜像下降

Require: $V \subseteq X \subseteq \mathbb{R}^d$, $\psi : X \rightarrow \mathbb{R}$ 在 $\text{int}(X)$ 上强凸且连续可微, $x_1 \in V$, ψ 在 x_1 处可微; $\eta_1, \dots, \eta_T > 0$

- 1: **for** $t = 1$ to T **do**
 - 2: 输出 x_t
 - 3: 接受 ℓ_t 并计算 $\ell_t(x_t)$
 - 4: 计算 $g_t \in \partial \ell_t(x_t)$
 - 5: 更新 $x_{t+1} = \arg \min_{x \in V} \langle g_t, x \rangle + \frac{1}{\eta_t} B_\psi(x; x_t)$
 - 6: **end for**
-

该算法可能存在问题，如果 $x_{t+1} \in \partial X$ ，那么在 x_{t+1} 处 Bregman 散度没有定义，更新无法继续下去。

要解决该问题，往往需要下面两个假设之一：

1.

$$\lim_{x \rightarrow \partial X} \|\nabla \psi(x)\|_2 = +\infty$$

2.

$$V \subseteq \text{int}(X)$$

下面我们要分析研究 OMD 的 regret 性质。



1 在线镜像下降

■ 从 OSD 出发与改进 ■ OMD 的性质

2 Follow The Regularized Leader

3 Parameter-free 在线学习

4 参考文献

引理 (1)

$\psi : X \rightarrow \mathbb{R}$ 在 V 中是关于 $\|\cdot\|$ λ -强凸的。设 $V \subseteq X$ 是一个凸集, $g_t \in \partial \ell_t(x_t)$ 。若上述两个条件之一成立, 那么 $\forall u \in V$, 下面的不等式成立:

$$\eta_t(\ell_t(x_t) - \ell_t(u)) \leq \eta_t \langle g_t, x_t - u \rangle \leq B_\psi(u; x_t) - B_\psi(u; x_{t+1}) + \frac{\eta_t^2}{2\lambda} \|g_t\|_*^2$$

证明.

由 OMD 更新的最优条件, 有:

$$\langle \eta_t g_t + \nabla \psi(x_{t+1}) - \nabla \psi(x_t), u - x_{t+1} \rangle \geq 0, \forall u \in V$$

左边的不等式是显然的。

$$\begin{aligned}
 & \langle \eta_t g_t, x_t - u \rangle \\
 = & \langle \nabla \psi(x_t) - \nabla \psi(x_{t+1}) - \eta_t g_t, u - x_{t+1} \rangle + \langle \nabla \psi(x_{t+1}) - \nabla \psi(x_t), u - x_{t+1} \rangle + \langle \eta_t g_t, x_t - x_{t+1} \rangle \\
 \leq & \langle \nabla \psi(x_{t+1}) - \nabla \psi(x_t), u - x_{t+1} \rangle + \langle \eta_t g_t, x_t - x_{t+1} \rangle \\
 = & B_\psi(u; x_t) - B_\psi(u, x_{t+1}) - B_\psi(x_{t+1}; x_t) + \langle \eta_t g_t, x_t - x_{t+1} \rangle \\
 \leq^{(*)} & B_\psi(u; x_t) - B_\psi(u, x_{t+1}) - B_\psi(x_{t+1}; x_t) + \frac{\eta_t^2}{2\lambda} \|g_t\|_*^2 + \frac{\lambda}{2} \|x_t - x_{t+1}\|^2 \\
 \leq & B_\psi(u; x_t) - B_\psi(u, x_{t+1}) + \frac{\eta_t^2}{2\lambda} \|g_t\|_*^2
 \end{aligned}$$

这里 (*) 由 Fenchel-Young 不等式可得, $\langle p, x \rangle \leq f(x) + f^*(p)$, 其中取 $f(x) = \frac{\lambda}{2} \|x\|^2$ 。

□

定理 (1)

设 $x_1 \in V$ 且 ψ 在 x_1 处可微, 且 $\eta_{t+1} \leq \eta_t$, $t = 1, \dots, T$. 那么在引理 1 的假设下, 下面的不等式成立:

$$\sum_{t=1}^T (\ell_t(x_t) - \ell_t(u)) \leq \max_{1 \leq t \leq T} \frac{B_\psi(u; x_t)}{\eta_t} + \frac{1}{2\lambda} \sum_{t=1}^T \eta_t \|g_t\|_*^2$$

如果 $\eta_t = \eta$ 为常数, 那么有:

$$\sum_{t=1}^T (\ell_t(x_t) - \ell_t(u)) \leq \frac{B_\psi(u; x_1)}{\eta} + \frac{\eta}{2\lambda} \sum_{t=1}^T \|g_t\|_*^2$$

证明.

对引理 1 的结论作累加, 得:

$$\begin{aligned}
 \sum_{t=1}^T (\ell_t(x_t) - \ell_t(u)) &\leq \sum_{t=1}^T \left(\frac{1}{\eta_t} B_\psi(u; x_t) - \frac{1}{\eta_t} B_\psi(u; x_{t+1}) \right) + \sum_{t=1}^T \frac{\eta_t}{2\lambda} \|g_t\|_*^2 \\
 &= \frac{1}{\eta_1} B_\psi(u; x_1) - \frac{1}{\eta_T} B_\psi(u; x_{T+1}) + \sum_{t=1}^{T-1} \left(\frac{1}{\eta_{t+1}} - \frac{1}{\eta_t} \right) B_\psi(u; x_{t+1}) + \sum_{t=1}^T \frac{\eta_t}{2\lambda} \|g_t\|_*^2 \\
 &\leq \frac{1}{\eta_1} D^2 + D^2 \sum_{t=1}^{T-1} \left(\frac{1}{\eta_{t+1}} - \frac{1}{\eta_t} \right) + \sum_{t=1}^T \frac{\eta_t}{2\lambda} \|g_t\|_*^2 \\
 &= \frac{D^2}{\eta_T} + \sum_{t=1}^T \frac{\eta_t}{2\lambda} \|g_t\|_*^2
 \end{aligned}$$

这里我们记: $D^2 = \max_{1 \leq t \leq T} B_\psi(u; x_t)$.



定理 (2)

$\psi : X \rightarrow \mathbb{R}$ 是 $\lambda > 0$ 强凸的。 $V \subseteq X$ 是一个闭凸集, 且 $\text{int}(X) \cap V \neq \emptyset$, 那么


$$\arg \min_{x \in V} \langle g_t, x \rangle + \frac{1}{\eta_t} B_\psi(x; x_t) = \nabla \psi_V^*(\nabla \psi_V(x_t) - \eta_t g_t)$$

其中 ψ_V 为将 ψ 限制到 V 上, $\psi_V = \psi + i_V$, $i_V(x) = \begin{cases} 0, & x \in V \\ +\infty, & x \notin V \end{cases}$

现在我們有一个新的更新公式

$$x_{t+1} = \nabla \psi_V^*(\nabla \psi_V(x_t) - \eta_t g_t),$$

这意味着什么?



- ▶ $\nabla\psi_V$ 和 $\nabla\psi_V^*$ 是从原空间和对偶空间转换的算子。
- ▶ 初始点 x_t , 转换到对偶空间 $\nabla\psi_V(x_t)$, 在对偶空间中次梯度下降。
- ▶ 通过 $\nabla\psi_V^*$ 转换回原空间。



- 1 在线镜像下降
- 2 Follow The Regularized Leader
 - FTRL 的 Regret 等式 ■ 线性损失下的 FTRL 算法及其应用
- 3 Parameter-free 在线学习
- 4 参考文献



- 1 在线镜像下降
- 2 Follow The Regularized Leader
 - FTRL 的 Regret 等式 ■ 线性损失下的 FTRL 算法及其应用
- 3 Parameter-free 在线学习
- 4 参考文献

在前面的算法中，我们对每一轮的更新都使用同样的正则项 ψ ，在 FTRL 算法中，我们在每一轮中优化过去的损失之和加上正则项作最优化。

Algorithm 2 FTRL

Require: 一系列正则项 $\psi_1, \dots, \psi_T: \mathbb{R}^d \rightarrow (-\infty, +\infty]$

- 1: **for** $t = 1$ to T **do**
 - 2: **输出** $x_t \in \arg \min_{x \in \mathbb{R}^d} \psi_t(x) + \sum_{i=1}^{t-1} \ell_i(x)$
 - 3: **接受** ℓ_t , 计算 $\ell_t(x_t)$
 - 4: **end for**
-

FTRL 是一族算法，就像 OMD 一样，随着正则项 ψ_1, \dots, ψ_T 变化而变化。



- ▶ 对于 OMD 而言, 模型当前的“状态”保存在 x_t 中, 更新 x_{t+1} 需要依赖于 x_t 和 ℓ_t 的信息。
- ▶ 对于 FTRL 而言, x_{t+1} 的更新依赖于过去的所有历史损失函数 ℓ_1, \dots, ℓ_t 。
- ▶ 因为要保留更多的信息, 我们可能认为 FTRL 在计算和内存方面更为昂贵。事实也确实如此。
- ▶ 但我们也将看到, 通过采用近似损失的方法, 可以使该算法的成本与 OMD 相当, 同时仍能保留比 OMD 更严格的信息。

引理 (2)

记 $F_t(x) = \psi_t(x) + \sum_{i=1}^{t-1} \ell_i(x)$ 。设 $\arg \min_{x \in \mathbb{R}^d} F_t(x) \neq \emptyset$, 且 $x_t \in \arg \min_{x \in \mathbb{R}^d} F_t(x)$, 那么对于 $\forall u$, 有

$$\sum_{t=1}^T (\ell_t(x_t) - \ell_t(u)) = \psi_{T+1}(u) - \min_x \psi_1(x) + \sum_{t=1}^T [F_t(x_t) - F_{t+1}(x_{t+1}) + \ell_t(x_t)] + F_{T+1}(x_{T+1}) - F_{T+1}(u)$$

该引理的证明如下:

证明.

因为 $\ell_t(x_t)$ 在两边同时出现, 所以实际上只需要验证:

$$-\sum_{t=1}^T \ell_t(u) = \psi_{T+1}(u) - \min_x \psi_1(x) + \sum_{t=1}^T [F_t(x_t) - F_{t+1}(x_{t+1})] + F_{t+1}(x_{t+1}) - F_{t+1}(u)$$

因为 $F_1(x_1) = \min_{x \in V} \psi_1(x)$, 所以

$$\begin{aligned} -\sum_{t=1}^T \ell_t(u) &= \psi_{T+1}(u) - F_1(x_1) + F_1(x_1) - F_{T+1}(x_{T+1}) + F_{T+1}(x_{T+1}) - F_{T+1}(u) \\ &= \psi_{T+1}(u) - F_{T+1}(u) \end{aligned}$$



然而 Regret 等式并不是一个 regret 上界的保证, 因为 ℓ_t 项在等式的两边出现。
在给出强凸情况下的 regret 上界之前, 我们给出两个关于强凸函数的引理。

引理 (3)

$f: \mathbb{R}^d \rightarrow (-\infty, +\infty]$ 关于范数 $\|\cdot\|$ 是 μ - 强凸的, 那么对于 $x, y \in \text{dom}(f), g \in \partial f(y), g' \in \partial f(x)$, 有

$$f(x) - f(y) \leq \langle g, x - y \rangle + \frac{1}{2\mu} \|g - g'\|_*^2$$

证明.

定义 $\varphi(z) = f(z) - \langle g, z \rangle$, 因为 $0 \in \partial\varphi(y)$, 因此 $y \in \arg \min_{z \in \text{dom}(\varphi)} \varphi(z)$, 另外, 因为 $g' - g \in \partial\varphi(x)$, 所以

$$\begin{aligned}\varphi(y) &= \min_{z \in \text{dom}(\varphi)} \varphi(z) \\ &\geq \min_{z \in \text{dom}(\varphi)} (\varphi(x) + \langle g' - g, z - x \rangle + \frac{\mu}{2} \|z - x\|^2) \\ &\geq \inf_{z \in \mathbb{R}^d} (\varphi(x) + \langle g' - g, z - x \rangle + \frac{\mu}{2} \|z - x\|^2) \\ &\stackrel{(*)}{=} \varphi(x) - \frac{1}{2\mu} \|g' - g\|_*^2\end{aligned}$$

其中 $(*)$ 来源于共轭函数的定义。

□

取 $y = x^*$, 那么 $0 \in \partial f(y)$, 于是有如下显然的推论:

推论 (1)

$f: \mathbb{R}^d \rightarrow (-\infty, +\infty]$ 关于范数 $\|\cdot\|$ 是 μ -强凸的, 设 $x^* = \arg \min_x f(x)$, 那么 $\forall x \in \text{dom}(f), g \in \partial f(x)$, 有

$$f(x) - f(x^*) \leq \frac{1}{2\mu} \|g\|_*^2$$

下面我们给出一个引理，衡量 FTRL 算法的稳定性——即相邻两次预测函数值之差的上界：

引理 (4)

在引理 2 的假设下，如果 F_t 是关于 $\|\cdot\|$ 的正常 λ_t -强凸函数，且 ℓ_t 是正常凸函数。另外假设 $\partial \ell_t(x_t) \neq \emptyset$ ，那么

$$F_t(x_t) - F_{t+1}(x_{t+1}) + \ell_t(x_t) \leq \frac{\|g_t\|_*^2}{2\lambda_t} + \psi_t(x_{t+1}) - \psi_{t+1}(x_{t+1})$$

对于任意的 $g_t \in \partial \ell_t(x_t)$ 成立。

证明.

$$\begin{aligned} F_t(x_t) - F_{t+1}(x_{t+1}) + \ell_t(x_t) &= (F_t(x_t) + \ell_t(x_t)) - (F_t(x_{t+1}) + \ell_t(x_{t+1})) + \psi_t(x_{t+1}) - \psi_{t+1}(x_{t+1}) \\ &\leq (F_t(x_t) + \ell_t(x_t)) - (F_t(x_t^*) + \ell_t(x_t^*)) + \psi_t(x_{t+1}) - \psi_{t+1}(x_{t+1}) \\ &\leq^{(*)} \frac{\|g_t\|_*^2}{2\lambda_t} + \psi_t(x_{t+1}) - \psi_{t+1}(x_{t+1}) \end{aligned}$$

其中不等式 (*) 成立是因为 $\partial \ell_t(x_t) \neq \emptyset$, 所以我们可以选择 $g'_t \in \partial \ell_t(x_t)$, 因为 $x_t = \arg \min_x F_t(x)$, 所以 $0 \in \partial F_t(x_t)$, 于是 $g'_t \in \partial(F_t(x_t) + \ell_t(x_t))$, 且 $x_t^* = \arg \min_x F_t(x) + \ell_t(x)$, 应用推论 1 即可。 □



- 1 在线镜像下降
- 2 Follow The Regularized Leader
 - FTRL 的 Regret 等式 ■ 线性损失下的 FTRL 算法及其应用
- 3 Parameter-free 在线学习
- 4 参考文献

当 ℓ_i 为线性函数时, FTRL 的更新公式可以写作:


$$x_{t+1} \in \arg \min_x \psi_{t+1}(x) + \sum_{i=1}^t \langle g_i, x \rangle = \arg \max_x \langle - \sum_{i=1}^t g_i, x \rangle - \psi_t(x)$$

由对偶函数的极大值条件, 有 $x_{t+1} \in \partial \psi_{t+1}^*(-\sum_{i=1}^t g_i)$
此外, 如果 ψ_{t+1} 强凸, 则 ψ_{t+1}^* 可微, 于是

$$x_{t+1} = \nabla \psi_{t+1}^*(-\sum_{i=1}^t g_i)$$

这一更新公式可以写作：

$$\begin{aligned}\theta_{t+1} &= \theta_t - g_t \\ x_{t+1} &= \nabla \psi_{t+1}^*(\theta_{t+1})\end{aligned}$$



OMD 也可以写成类似的形式：

$$\begin{aligned}\theta_{t+1} &= \nabla\psi(x_t) - \eta_t g_t \\ x_{t+1} &= \nabla\psi^*(\theta_{t+1})\end{aligned}$$

- ▶ OMD 算法中，状态保存在 x_t 中，所以要用 $\nabla\psi$ 转化到对偶空间来更新，再转回到原空间中。
- ▶ 线性损失 FTRL 中，状态就在对偶空间中，所以直接进行更新，原空间只用来做预测，不用来更新。
- ▶ OMD 中，学习率 η_t 通常是递减的，样本权重逐渐减小。
- ▶ 线性损失 FTRL 中，次梯度的权重都相同，但正则项通常是增加的。

Algorithm 3 线性损失 FTRL

Require: 一系列正则项 $\psi_1, \dots, \psi_T: \mathbb{R}^d \rightarrow (-\infty, +\infty]$

- 1: **for** $t = 1$ to T **do**
 - 2: **输出** $x_t \in \arg \min_{x \in \mathbb{R}^d} \psi_t(x) + \sum_{i=1}^{t-1} \langle g_i, x \rangle$
 - 3: **接受** ℓ_t , **计算** $\ell_t(x_t)$
 - 4: **计算** $g_t \in \partial \ell_t(x_t)$
 - 5: **end for**
-

考虑 $V = \{x \in \mathbb{R}^d : \|x\|_2 \leq 1\}$, 先考虑 OMD, 正则项函数 $\psi(x) = \frac{\|x\|_2^2}{2}$, 学习率 $\eta_t = \frac{1}{\sqrt{t}}$, $x_1 = 0$, 那么更新公式为:

$$\begin{aligned}\tilde{x}_{t+1} &= x_t - \frac{1}{\sqrt{t}} g_t \\ x_{t+1} &= \tilde{x}_{t+1} \min\left(\frac{1}{\|\tilde{x}_{t+1}\|^2}, 1\right)\end{aligned}$$

对于线性损失 FTRL, 使用 $\psi_t(x) = \frac{\sqrt{t}}{2} \|x\|_2^2 + i_V(x)$, 那么其更新公式为:

$$\begin{aligned}\tilde{x}_{t+1} &= \frac{-\sum_{i=1}^t g_i}{\sqrt{t}} \\ x_{t+1} &= \tilde{x}_{t+1} \min\left(\frac{1}{\|\tilde{x}_{t+1}\|^2}, 1\right)\end{aligned}$$

直觉上, FTRL 会使用更多的信息, 而 OMD 只使用前面一步的结果。

- 1 在线镜像下降
- 2 Follow The Regularized Leader
- 3 Parameter-free 在线学习
 - 从 Coin-Betting 开始 ■ 通过 Coin-Betting 推导 Parameter-free 的一维 OCO
- 4 参考文献

- 1 在线镜像下降
- 2 Follow The Regularized Leader
- 3 Parameter-free 在线学习
 - 从 Coin-Betting 开始 ■ 通过 Coin-Betting 推导 Parameter-free 的一维 OCO
- 4 参考文献

重复进行以下游戏：

- ▶ 初始时，拥有财富 ϵ ： $Wealth_0 = \epsilon$
- ▶ 在 $t = 1, \dots, T$ 的每一轮中：
 - ▶ 赌上价值 $|x_t|$ 的财富在 $sign(x_t)$ 代表的硬币一面，你不能赌上比你现在拥有的更多的钱。
 - ▶ 抛硬币决定结果： $c_t \in \{-1, 1\}$
 - ▶ 获得财富： $c_t x_t$ ，即： $Wealth_t = Wealth_{t-1} + c_t x_t = \epsilon + \sum_{i=1}^t c_i x_i$

因为不允许借钱，所以可以记 $x_t = \beta_t Wealth_{t-1}$ ，这里 $\beta_t \in [-1, 1]$ ， $|\beta_t|$ 是赌上的财富占比， $sign(\beta_t)$ 是赌注的硬币朝向。

我们在这个游戏中没法一直赢下去，所以我们目标是尽量跑过一个在正常游戏中采用固定的 β^* 的策略。

$$\begin{aligned}\text{Wealth}_t &= \text{Wealth}_{t-1} + c_t x_t = \text{Wealth}_{t-1} + c_t \beta_t \text{Wealth}_{t-1} = \text{Wealth}_{t-1} (1 + c_t \beta_t) \\ &= \epsilon \prod_{i=1}^t (1 + c_i \beta_i)\end{aligned}$$

我们希望最小化下面的 regret:

$$\begin{aligned}& \ln \max_{\beta \in [-1, 1]} \epsilon \prod_{t=1}^T (1 + \beta c_t) - \ln \text{Wealth}_T \\ &= \ln \max_{\beta \in [-1, 1]} \epsilon \prod_{t=1}^T (1 + \beta c_t) - \ln(\epsilon \prod_{t=1}^T (1 + \beta_t c_t)) \\ &= \max_{\beta \in [-1, 1]} \sum_{t=1}^T \ln(1 + \beta c_t) - \sum_{t=1}^T \ln(1 + \beta_t c_t)\end{aligned}$$

这实际上和损失函数 $\ell_t(x) = -\ln(1 + xc_t)$, $V = [-1, 1]$ 的在线凸优化 (OCO) 问题是一致的, 这里我们允许硬币是连续的, 因而 $c_t \in [-1, 1]$ 。

我们可以对这个问题去应用 OMD 或者 FTRL 算法, 但事实上对这个问题存在着一个特定的策略, 叫做 Krichevsky-Trofimov (KT) 投注。

Algorithm 4 Krichevsky-Trofimov (KT) 投注

Require: 初始财富 $Wealth_0 = \epsilon > 0$

- 1: **for** $t = 1$ to T **do**
 - 2: 计算投注比例 $\beta_t = \frac{\sum_{i=1}^{t-1} c_i}{t}$
 - 3: 进行投注: $x_t = \beta_t Wealth_{t-1}$
 - 4: 获取硬币的结果: $c_i \in [-1, 1]$
 - 5: 得到或失去对应的财富: $Wealth_t = Wealth_{t-1} + c_t x_t$
 - 6: **end for**
-

对于这一策略，其经过 T 轮后的财富有一个下界：

定理 (3)

[1](Cesa-Bianchi, N. and Lugosi, G. , 2006, Theorem 9.4) 如果 $c_t \in \{-1, 1\}$ 对于 $t = 1, 2, \dots, T$ 都成立，那么 KT 投注策略有下界：

$$\ln \text{Wealth}_T \geq \ln \max_{\beta \in [-1, 1]} \prod_{t=1}^T (1 + \beta c_t) - \frac{1}{2} \ln T - K$$

最优的固定 β 的策略中，财富变化的倍数有一个指数下界：

引理 (5)

如果 $g_t \in \{-1, 1\}$, $t = 1, \dots, T$, 那么我们有：

$$\max_{\beta \in [-1, 1]} \exp\left(\sum_{t=1}^T \ln(1 - \beta g_t)\right) \geq \exp\left(\sum_{t=1}^T \frac{(\sum_{t=1}^T g_t)^2}{4T}\right)$$

证明.

$$\begin{aligned} \max_{\beta \in [-1, 1]} \exp\left(\sum_{t=1}^T \ln(1 - \beta g_t)\right) &\geq \max_{\beta \in [-1/2, 1/2]} \exp\left(\sum_{t=1}^T \ln(1 - \beta g_t)\right) \\ &\geq \max_{\beta \in [-1/2, 1/2]} \exp\left(\beta \sum_{t=1}^T g_t - \beta \sum_{t=1}^T g_t^2\right) (\ln(1+x) \geq x - x^2) \\ &\geq \max_{\beta \in [-1/2, 1/2]} \exp\left(\beta \sum_{t=1}^T g_t - \beta^2 T\right) = \exp\left(\frac{(\sum_{t=1}^T g_t)^2}{4T}\right) \end{aligned}$$

□

KT 投注策略保证了一个指数下界，而仅仅付出 \sqrt{T} 的代价。注意到 KT 投注策略不需要设定任何额外的超参数，如学习率、正则项等等，也就是说，KT 投注策略是 Parameter-free 的。

另外，我们也可以将 KT 投注策略拓展到连续硬币的情况：

定理 (4)

(Orabona, F. and Pal, D., 2016, Lemma 14) 如果 $c_t \in [-1, 1]$ 对于 $t = 1, 2, \dots, T$ 都成立，那么 KT 投注策略有下界：

$$\ln \text{Wealth}_T \geq \sum_{t=1}^T \frac{(\sum_{t=1}^T c_t)^2}{4T} - \frac{1}{2} \ln T - K$$

- 1 在线镜像下降
- 2 Follow The Regularized Leader
- 3 Parameter-free 在线学习
 - 从 Coin-Betting 开始 ■ 通过 Coin-Betting 推导 Parameter-free 的一维 OCO
- 4 参考文献



首先, Coin-Betting 问题等价于, 设计一个算法来最小化下面的带线性损失的一维 regret:

$$\text{Regret}_T(u) = \sum_{t=1}^T g_t x_t - \sum_{t=1}^T g_t u$$

另外, OCO 问题可以被简化为在线线性优化 (OLO) 问题。

于是, 我们可以联想到, 可以将 OCO 问题用 Coin-Betting 算法的形式来解决。

下面的定理允许我们在 OLO 和 Coin-Betting 问题之间做转换:



定理 (4)

$\phi : \mathbb{R}^d \rightarrow (-\infty, +\infty]$ 是一个合理闭凸函数, $\phi^* : \mathbb{R}^d \rightarrow (-\infty, +\infty]$ 是它的 Fenchel 共轭。某个算法产生某个序列 x_1, x_2, \dots, x_T , 它保证

$$\forall g_1, \dots, g_T \in \mathbb{R}^d, \epsilon - \sum_{t=1}^T \langle g_t, x_t \rangle \geq \phi\left(-\sum_{t=1}^T g_t\right)$$

当且仅当它保证:

$$\forall u \in \mathbb{R}^d, \text{Regret}_T(u) = \sum_{t=1}^T \langle g_t, x_t - u \rangle \leq \phi^*(u) + \epsilon$$

证明.

从左到右:

$$\begin{aligned}\text{Regret}_T(u) &= \sum_{t=1}^T \langle g_t, x_t - u \rangle \leq -\sum_{t=1}^T \langle g_t, u \rangle - \phi\left(-\sum_{t=1}^T g_t\right) + \epsilon \\ &\leq \sup_{\theta \in \mathbb{R}^d} \langle \theta, u \rangle - \phi(\theta) + \epsilon = \phi^*(u) + \epsilon\end{aligned}$$

从右到左:

$$\begin{aligned}-\sum_{t=1}^T \langle g_t, x_t \rangle &= -\sum_{t=1}^T \langle g_t, u \rangle - \sum_{t=1}^T \langle g_t, x_t - u \rangle \\ &= \sup_{u \in \mathbb{R}^d} -\sum_{t=1}^T \langle g_t, u \rangle - \sum_{t=1}^T \langle g_t, x_t - u \rangle \\ &\geq \sup_{u \in \mathbb{R}^d} -\sum_{t=1}^T \langle g_t, u \rangle - \phi^*(u) - \epsilon = \phi\left(-\sum_{t=1}^T g_t\right) - \epsilon\end{aligned}$$

□

首先我们可以在一维 OLO 和 Coin-betting 问题之间进行转化：令 $c_t = -g_t$ ，于是就有 Coin-betting 算法给出：

$$\text{Wealth}_T = \epsilon + \sum_{t=1}^T x_t c_t = \epsilon - \sum_{t=1}^T x_t g_t$$

根据定理 4，如果 Wealth_T 能有一个被 $\sum_{t=1}^T c_t$ 的函数表示的下界，则对应 OLO 问题也有对应的下界，这个过程中我们只需要计算出 ϕ 的 Fenchel 共轭。最后将一维 OCO 问题简化为一维 OLO 问题：

$$\text{Regret}_T(u) = \sum_{t=1}^T \ell_t(x_t) - \sum_{t=1}^T \ell_t(u) \leq \sum_{t=1}^T x_t g_t - \sum_{t=1}^T g_t u, g_t \in \partial \ell_t(x_t)$$

回忆 KT 算法, 初始财富为 ϵ , 每次赌注时 KT 算法赌上 $x_t = \beta_t \text{Wealth}_{t-1}$ 的财富。
令 $c_t = -g_t$, $g_t \in \partial \ell_t(x_t)$, 且假设 ℓ_t 是 1-Lipschitz 的, 所以我们得到

$$x_t = -\frac{\sum_{i=1}^{t-1} g_i}{t} (\epsilon - \sum_{i=1}^{t-1} g_i x_i)$$

Algorithm 5 KT OCO

Require: $\epsilon > 0$ (1 到 \sqrt{T} 之间的任何数)

- 1: **for** $t = 1$ to T **do**
 - 2: 输出 $x_t = -\frac{\sum_{i=1}^{t-1} g_i}{t} (\epsilon - \sum_{i=1}^{t-1} g_i x_i)$
 - 3: 接受 ℓ_t , 支付 $\ell_t(x_t)$
 - 4: 令 $g_t \in \partial \ell_t(x_t)$
 - 5: **end for**
-



- 1 在线镜像下降
- 2 Follow The Regularized Leader
- 3 Parameter-free 在线学习
- 4 参考文献

1. Cesa-Bianchi, Nicolo, and Gábor Lugosi. Prediction, learning, and games. Cambridge university press, 2006.
2. Orabona, Francesco, and Dávid Pál. "Coin betting and parameter-free online learning." Advances in Neural Information Processing Systems 29 (2016).
3. Francesco Orabona. "Introduction to Online Learning"
<https://parameterfree.com/lecture-notes-on-online-learning/>
 - ▶ Online Mirror Descent I: Bregman version
 - ▶ Online Mirror Descent II: Regret and Mirror Version
 - ▶ Follow-The-Regularized-Leader I: Regret Equality
 - ▶ Parameter-free Online Learning I: Coin-Betting and 1-d OCO



谢谢!